LABORATUVAR 7 · FİRMA SÜRÜMÜ · FADA Otonom Transfer Arabası

7

# AI Safety Challenge

Çıktı: AI Fail-Safe Decision

Ad Soyad **Muhammed Salih Atiç** | Grup | Tarih **28.10.2026**

**Kavram — Prediction ≠ Safety:** Yapay zekâ bir karar üretir; güvenliği garanti eden mimari YZ'nin dışında tanımlanmalıdır. Araçlar: **fail-safe · human override · monitoring · confidence threshold · fallback.**

**Bu makinedeki YZ görevi:** Araç kalkmadan önce, araç üstü 3D kamera ve YZ modeli trafonun taşıma beşiğine doğru ve dengeli oturup oturmadığını sınıflandırır. **OK** → hareket izni ve normal hız profili. **RED** → hareket yok. *Kişi algılama bilinçli olarak YZ'ye bırakılmamıştır; sertifikalı lazer tarayıcı + Safety PLC'de kalır.*

3D Kamera (yük ve beşik görüntüsü) → YZ Modeli (yük oturma kontrolü) → OK / RED → Parametre (hareket izni · hız profili) → Araç tahriki

## Görev — üç başarısızlıkta güvenli davranış

1. Model yanlış sınıflandırdı: Kusurlu parçaya OK verdi. Sistem ne yapmalı? İkinci kontrol / insan onayı var mı?

   Evet, iki bağımsız katman olmalı. **İkinci kontrol:** YZ'den bağımsız, deterministik ölçüm. Araç akslarındaki yük hücreleri ağırlık dağılımını ve ağırlık merkezini hesaplar, eşik dışındaysa YZ "OK" dese bile hareket engellenir. İlk metrelerde düşük hızla "sürünme" yapılır, eğim/yük kayması algılanırsa araç durur. **İnsan onayı:** belirli tonajın üzerindeki kritik yüklerde operatör görsel kontrol yapıp kalkışı onaylar.

2. Girdi manipüle edildi: Kamera verisi bozuk/sahte. Nasıl fark edilir? Şüpheli girdide ne yapılır?

   **Fark etme:** kamera sonucu ile yük hücresi verisi çapraz doğrulanır (görüntü "dengeli" derken ağırlık dağılımı dengesizse tutarsızlık var); görüntü akışının bütünlüğü ve zaman damgası kontrol edilir (donmuş/tekrarlanan kare, imzasız akış); lens kapatma, ani ışık ve odak anomalileri izlenir. **Şüpheli girdide:** YZ kararı geçersiz sayılır, otomatik hareket izni verilmez. Araç yalnızca manuel modda, operatör kontrolünde ve düşük hızda hareket eder. Olay kaydedilir ve güvenlik ekibine uyarı gider.

3. Confidence düştü: Model "emin değilim" diyor. Eşik ne olmalı? Altında: dur / insana sor / fallback?

   Eşikler, doğrulama verisinde ölçülen hata oranlarına göre belirlenir. Başlangıç önerisi: **≥ 0,95 → OK** (yine yük hücresi kontrolünden geçer) · **0,80–0,95 → insana sor** (operatör görsel kontrol + onay) · **< 0,80 → dur** ve fallback (YZ devre dışı, manuel mod ve klasik sensör kontrolüyle devam). Düşük güvenli kararlar loglanır ve modelin yeniden eğitimi için kullanılır (monitoring).

## Karar tablosu — AI Fail-Safe Decision

| Başarısızlık | Tanımladığınız güvenli davranış (hangi kavramla?) |
|---|---|
| **Model yanlış sınıflandırdı** | Bağımsız yük hücresi kontrolü hareketi engeller; kritik yükte operatör onayı; ilk metrelerde sürünme testi → **fail-safe + human override** |
| **Girdi manipüle edildi** | Kamera ↔ yük hücresi çapraz doğrulama, akış bütünlüğü kontrolü; şüphede otomatik izin yok, manuel moda geç, alarm → **monitoring + fallback** |
| **Confidence düştü** | ≥0,95 OK · 0,80–0,95 insana sor · <0,80 dur + manuel mod; tüm düşük güvenli kararlar loglanır → **confidence threshold + human override + fallback** |

Bu föyün çıktısı **AI Fail-Safe Decision** → Evidence Pack **EP 03 + EP 15** başlığına oturur.